分布式键值存储系统

翟锦洋、付涛

January 2, 2026

中国科学院大学

Table of Contents

实现功能

1 项目概述

- 设计并实现键值数据的多机分布式数据存储，采用 RPC 通信协议。
- 支持数据的增加、修改和删除操作
- 支持记录的多副本存储
- 提供读写接口/检索界面访问数据存储
- 支持 raft 一致性协议模块，故障情况下实现保证可靠存储
- 实现元数据管理

Table of Contents

整体架构图

2 meta-server 架构

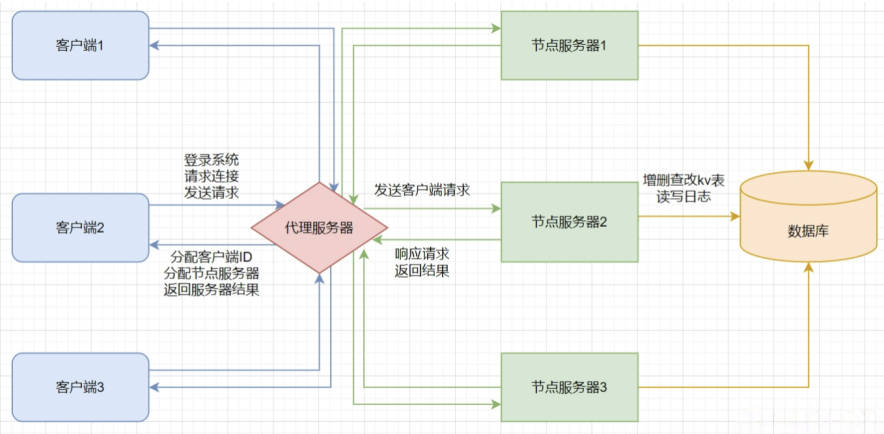

整体架构

2 meta-server 架构

应用架构

应用采用三层分布式架构，客户端通过代理服务器与节点服务器通信。代码组织上，使用 Python 语言实现 meta-server；使用 XML-RPC 实现客户端与服务器之间的通信；使用 Flask 实现 HTTP 测试服务器，使用 requests 库实现节点服务器与 Raft 集群的 HTTP 通信。

```
meta-server/
|-- client.py // 客户端实现
|-- proxy_server.py // 代理服务器
|-- node_server.py // 节点服务器
|-- test_flask.py // Flask测试服务器
|-- api.md // API文档
|-- requirements.txt // 依赖管理
```

系统架构概览

2 meta-server 架构

三层架构

- **客户端**：用户交互界面
- **代理服务器**：请求路由和负载分配
- **节点服务器**：业务逻辑处理

通信方式

- 客户端 ↔ 代理服务器：XML-RPC
- 代理服务器 ↔ 节点服务器：XML-RPC
- 节点服务器 ↔ Raft 集群：HTTP

组件说明

2 meta-server 架构

客户端 (client.py)

- **功能**：用户交互界面
- **通信方式**：XML-RPC
- **主要特性**：
  - 用户认证（用户名/密码）
  - 客户端 ID 分配
  - 命令解析与执行

组件说明

2 meta-server 架构

代理服务器 (proxy_server.py)

- **功能**：请求路由和负载分配
- **端口**：21000
- **主要特性**：
  - 用户认证管理
  - 客户端 ID 分配与管理
  - 命令转发到对应的节点服务器
  - 响应格式化与错误处理

组件说明

2 meta-server 架构

节点服务器 (node_server.py)

- **功能**：业务逻辑处理层
- **端口**：20000 + server_id
- **主要特性**：
  - 键值对操作（PUT、GET、DEL、LIST）
  - 集群管理操作（ADD-LEARNER、CHANGE-MEMBERSHIP、METRICS）
  - 操作日志记录
  - HTTP 请求封装

数据操作 API

2 meta-server 架构

支持的命令

- **PUT**：添加或更新键值对
- **GET**：读取单个键值
- **DEL**：删除键值对
- **LIST**：读取所有键值对

PUT 操作

2 meta-server 架构

功能特点

- **API 端点**：`POST /write`
- **请求格式**：`{"Put": {"key": "key", "value": "value"}}`
- **响应**：`"Ok"` 或 `"Err"`
- **特点**：自动区分添加和更新操作

代码示例

```
json_data = {"Put": {"key": key, "value": value}}
response = self._http_request('/write', json_data=json_data)
```

GET 操作

2 meta-server 架构

功能特点

- **API 端点**：`POST /read`
- **请求格式**：字符串 `"key"`
- **响应格式**：`{"Ok": "value"}` 或 `{"Ok": ""}`
- **特点**：支持缓存机制（可选）

代码示例

```
json_data = key
response = self._http_request('/read', json_data=json_data, method='POST')
```

DEL 和 LIST 操作

2 meta-server 架构

DEL 操作

- **API 端点**：`POST /write`
- **请求格式**：`{"Del": {"key": "key"}}`
- **响应**：`"Ok"` 或 `"Err"`

LIST 操作

- **API 端点**：`GET /read-all`
- **响应格式**：`{"Ok": [{...}, ...]}`
- **特点**：返回完整数据库快照

集群管理 API

2 meta-server 架构

ADD-LEARNER

- **功能**：添加 Raft 节点作为 learner
- **API 端点**：`POST /add-learner`
- **请求格式**：`[node_id, "api_addr"]`

CHANGE-MEMBERSHIP

- **功能**：改变集群成员关系
- **API 端点**：`POST /change-membership`
- **请求格式**：`[node_id1, node_id2, ...]`

METRICS 操作

2 meta-server 架构

功能

查询集群状态，返回详细信息：

- 节点基本信息：ID、任期、状态、Leader
- 投票信息、日志信息、成员配置
- 心跳信息、复制信息

用途

集群监控和诊断

客户端连接流程

2 meta-server 架构

认证和连接

```
def connect(self, username, password):
    self.port = '21000'
    self.proxy = xmlrpclib.ServerProxy(
        'http://localhost:' + self.port)
    if self.proxy.authenticate(username, password):
        self.id = self.proxy.get_id()
        return self.id
    return None
```

命令处理流程

2 meta-server 架构

代理服务器命令路由

```
def function(self, client_id, clause):
    clause = clause.lower().strip().split()
    command = clause[0]
    if command in ['put', 'get', 'del', ...]:
        method_name = command
        server_function = getattr(self, method_name)
        return server_function(client_id, clause)
```

PUT 操作实现

2 meta-server 架构

节点服务器 PUT 方法

```
def put(self, key, value):
    existing_value = self.get(key)
    json_data = {"Put": {"key": key, "value": value}}
    response = self._http_request('/write', json_data=json_data)
    if response == "Ok":
        self.write_log(f"添加key: {key}, value: {value}")
        return True
    return False
```

Flask API 测试端点

HTTP 接口

- `POST /write`：写入操作（Put/Del）
- `POST /read`：读取单个键值
- `GET /read-all`：读取所有键值
- `POST /add-learner`：添加 learner 节点
- `POST /change-membership`：改变成员关系
- `GET /metrics`：查询集群状态
- `GET /health`：健康检查

Flask API 示例

2 meta-server 架构

写入操作实现

```
@app.route('/write', methods=['POST'])
def write():
    data = request.get_json()
    if 'Put' in data:
        put_data = data['Put']
        key = put_data.get('key')
        value = put_data.get('value')
        with db_lock:
            database[key] = value
        return "Ok", 200
    ...
```

Table of Contents

3 kv-store 架构

整体架构

3 kv-store 架构

应用架构

应用采用多节点分布式架构，每个节点运行独立的 Raft 实例。代码组织上，使用 rust 语言实现 kv-store；使用 openraft 实现 raft 协议提供一致性保证；使用 actix-web 实现 http 服务器，使用 rust bTreeMap 和 RocksDB 实现存储层。

```
kv-store/
|-- src/
|   |--  lib.rs // 集群实现
|   |-- app.rs // 集群声明
|   |-- bin/main.rs // 主入口
|   |-- store/ // 存储层
|   |   |-- mod.rs // 存储层实现
|   |    -- log_store.rs // 日志存储
|   |-- network // 网络层
|   |   |-- mod.rs // 网络层实现
|   |   |-- api.rs // 业务 API
|   |   |-- management.rs // 管理 API
|   |    -- raft.rs // raft协议实现
|   |-- openraft_network // openraft网络层
|-- test.sh // 测试脚本
 -- start.sh // 启动脚本
```

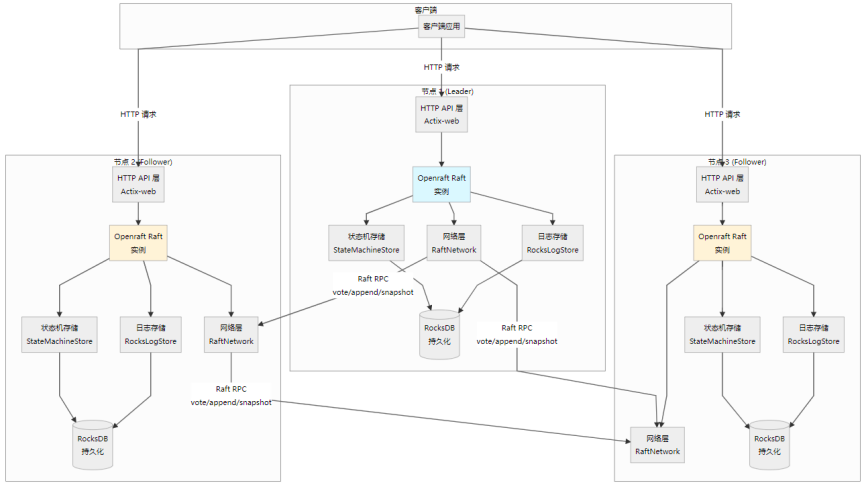
客户端
客户端应用
HTTP 请求
HTTP 请求
HTTP 请求
节点 1 (Leader)
HTTP API 层
Actix-web
Openraft Raft
实例
状态机存储
StateMachineStore
网络层
RaftNetwork
日志存储
RocksLogStore
Raft RPC
vote/append/snapshot
RocksDB
持久化
Raft RPC
vote/append/snapshot
节点 2 (Follower)
HTTP API 层
Actix-web
Openraft Raft
实例
状态机存储
StateMachineStore
日志存储
RocksLogStore
网络层
RaftNetwork
Raft RPC
vote/append/snapshot
RocksDB
持久化
节点 3 (Follower)
HTTP API 层
Actix-web
Openraft Raft
实例
状态机存储
StateMachineStore
日志存储
RocksLogStore
网络层
RaftNetwork
RocksDB
持久化

核心组件

3 kv-store 架构

1. Raft 节点 (src/lib.rs)

- 每个节点包含一个 openraft::Raft<TypeConfig> 实例
- 节点通过 HTTP 服务（Actix-web）暴露 RPC 和业务 API

2. 存储层 (src/store/)

- **日志存储** (RocksLogStore): 基于 RocksDB 持久化 Raft 日志条目
- **状态机存储** (StateMachineStore): 管理 KV 数据状态，实现日志应用到状态机

3. 网络层 (src/openraft_network/)

- 实现 RaftNetwork 和 RaftNetworkFactory，处理节点间 RPC 通信
- 通过 HTTP 传输 Raft 协议消息（vote、append_entries、install_snapshot）

存储层实现

3 kv-store 架构

日志存储 (RocksLogStore)

`RocksLogStore` 实现 `RaftLogStorage<TypeConfig>`:

- **持久化**: 使用 RocksDB `logs` column family 存储日志条目
- **元数据**: 使用 `meta` column family 存储 vote 和 last_purged_log_id
- **方法**:
  - `append()`: 追加日志条目并刷新 WAL
  - `truncate()`: 截断冲突日志
  - `purge()`: 清理已应用日志
  - `get_log_state()`: 获取日志状态

状态机存储 (StateMachineStore)

`StateMachineStore` 实现 `RaftStateMachine<TypeConfig>`:

- **状态管理**: `BTreeMap<String, String>` 存储 KV 数据
- **日志应用** (`apply()`):
  - 处理 `Put/Del` 请求，更新状态机
  - 处理 `Membership` 变更
  - 更新 `last_applied_log_id`
- **快照**:
  - `build_snapshot()`: 序列化状态机数据
  - `install_snapshot()`: 从快照恢复状态机

网络层实现

3 kv-store 架构

Network 实现 `RaftNetwork<TypeConfig>`

- **RPC 方法**:
  - `vote()`: 选举投票
  - `append_entries()`: 日志复制
  - `install_snapshot()`: 快照传输
- **通信方式**: HTTP POST 请求，JSON 序列化

Raft RPC 接口

- `POST /vote`：选举投票
- `POST /append`：日志复制
- `POST /snapshot`：快照传输

API 层设计 (src/network/)

3 kv-store 架构

管理 API

- `POST /init`：初始化集群
- `POST /add-learner`：添加 learner 节点
- `POST /change-membership`：改变成员关系
- `GET /metrics`：查询集群状态

业务 API

- `POST /write`：KV 写入操作（Put/Del）
- `POST /read`：KV 读取操作（单个键值）
- `GET /read-all`：读取所有键值对

写入流程（Put/Delete）

3 kv-store 架构

流程说明

/write API 接受 Request 类型的请求，支持两种操作：Put 用于插入或更新键值对，Del 用于删除指定键。write 的语义是修改状态机，即添加一条 log 日志。

执行步骤

1. 客户端调用 /write API
2. Raft.client_write() 将请求追加到日志
3. Leader 复制日志到多数节点
4. 日志提交后，apply() 应用到状态机
5. 返回响应给客户端

写入流程实现

3 kv-store 架构

src/mod.rs fn apply()

```
EntryPayload::Normal(req) => match req {
    Request::Put { key, value } => {
        let mut st = self.data.kvs.write().await;
        st.insert(key, value.clone());
        Response { value: Some(value) }
    }
    Request::Del { key } => {
        let mut st = self.data.kvs.write().await;
        st.remove(&key);
        Response { value: Some("Ok".to_string()) }
    }
}
```

读取流程

3 kv-store 架构

流程说明

读取操作直接从状态机读取，无需经过 Raft 协议。

执行步骤

1. 客户端调用 `/read` 或 `/read-all` API
2. 直接从 `app.key_values`（状态机数据）读取
3. 返回查询结果

读取流程实现

直接从状态机读取 (src/network/api.rs)

```
#[post("/read")]
pub async fn read(app: Data<App>, req: Json<String>)
    -> actix_web::Result<impl Responder> {
    let key = req.0;
    let kvs = app.key_values.read().await;
    let value = kvs.get(&key);

    let res: Result<String, Infallible> =
        Ok(value.cloned().unwrap_or_default());
    Ok(Json(res))
}
```

测试场景

3 kv-store 架构

test.sh

- **集群初始化**：启动 3 个未初始化的节点，初始化节点 1 为单节点集群（Leader）
- **成员管理**：添加节点 2 和节点 3 为 learner，将集群从单节点 [1] 扩展为三节点 [1，2，3]
- **数据写入**：在 Leader 节点写入键值对，验证数据已复制到所有节点
- **数据读取**：从所有节点（Leader 和 Followers）读取数据，验证一致性
- **数据删除**：测试删除键值对，验证删除操作在所有节点生效
- **模拟故障**：杀死 Leader 节点（节点 1），验证剩余节点选举出新 Leader，在新 Leader 上继续写入和读取
- **节点恢复**：重启节点 1，验证节点 1 能够从快照或日志恢复状态，验证恢复后数据一致性

Table of Contents

4 总结

项目总结

4 总结

meta-server

- 实现客户端登录与节点分配
- 支持完整数据操作（增删改查）接口
- 实现了 raft 节点管理、集群状态监控

kv-store

- 基于 Openraft 保证据一致性，实现了日志与状态机同步
- 使用 RocksDB 进行日志、状态机和数据快照的持久化存储
- 测试了节点故障和恢复，具有容错性

分布式键值存储系统

Thank you for listening!
Any questions?